

一、大语言模型 00:21

1. 概念与历史 01:36

1) 语言模型 01:39

语言模型

$$p(s) = p(w_1)p(w_2|w_1)p(w_3|w_1, w_2) \cdots p(w_m|w_1, \dots, w_{m-1}) =$$

床前明月【光】； 延安【根】，军工【魂】，领军【人】

图片来源:网络

• s=“我对象说”
 • 字符度: $p(s)=p(\text{我}) \cdot p(\text{对}|\text{我}) \cdot p(\text{象}|\text{我对}) \cdot p(\text{说}|\text{我对象})$ 。
 • 词粒度: $p(s)=p(\text{我}) \cdot p(\text{对象}|\text{我}) \cdot p(\text{说}|\text{我,对象})$
 $p(s)=p(\text{我}) \cdot p(\text{对我}) \cdot p(\text{象}|\text{我,对}) \cdot p(\text{说}|\text{我,对象})$

n-gram模型: 只考虑前后n个单元, 一元模型(汉语: 10K参数); 二元模型(汉语: 1.5M参数); 三元模型(传统上现1B参数)

张华平


- 语言模型本质: 计算一句话出现最大概率的生成组合方式。
 - 核心公式: $p(s) = p(w_1)p(w_2|w_1)p(w_3|w_1, w_2) \cdots p(w_m|w_1, \dots, w_{m-1})$
- 语言分布概率的奇妙特性:
 - 上下文依赖性: 语言概率分布不是一成不变的, 增加一个字或标点, 结果可能截然不同。
 - 举例: “我对象说国庆带我出去玩”, 正常理解“对象”是男朋友; 若后面接“象说: 不带”, 则“象”被理解为大象。
 - 文化/领域相关性: 不同群体对同一前缀的接续概率不同。
 - 举例: “床前明月”后, 大众接“光”; 北理工人接“延安【根】”, 军工【魂】, 领军【人】”。
- 传统n-gram模型: 只考虑前后n个单元的概率。
 - 一元模型(汉语约10K参数)、二元模型(汉语约1.5M参数)、三元模型(传统上约1B参数)。

2) 语言模型的发展历程 03:36




- **发展脉络：** 从1950s的统计语言模型（n-gram），到2003年的深度学习语言模型（NNLM），再到2017年的预训练语言模型（Transformer），最终演进至2021年后的超大规模预训练模型（ChatGPT、DeepSeek等）。
- **大模型“大”在何处：**
 - **上下文更长：** 从传统n-gram的3个字/词，扩展到现在的3万个字/词甚至更大。
 - **学习样本更大：** 从过去仅基于2年人民日报（约2亿字）的训练，发展到如今包含人类所有常识和知识（数个TB数据）的训练。

3) 新质生产力与大模型 04:43



- **大模型定位：** 人工智能与大数据的集大成者，是新质生产力的两个重要元素。
- **AI本质：** 个性服务的规模化新质生产力。

4) 全球大模型发展现状 05:14




- **总体趋势：** 全球大模型总体能力急剧增长，模型参数日趋增大，能力逐步攀升。
- **主要玩家：** 美国（OpenAI、Anthropic）和中国（DeepSeek、阿里千问、Kimi等）。


5) 大模型技术发展前景 05:54



-
- 李飞飞世界模型（Marble）：核心观点是“智能无法脱离身体存在”，能将平面图片演化为3D世界，验证模型是否真正理解世界。



- - 杨立昆世界模型（JEPA）：联合嵌入预测架构，能预测视频中与被遮挡部分在抽象表示空间中的内容。
- 6) 大模型发展趋势的基本估计 06:37



●

- **基准饱和：** 多项传统能力基准接近人类或饱和区间（如比赛成绩98、99分），继续拉开差距变难。
- **主流形态演进：** 从Copilot（辅助）走向Agent（代理），模型以更低成本嵌入真实工作流程，稳定完成任务。
 - 未来被大量使用的不是裸模型，而是“模型+记忆+数据+工具+权限+工作流”的组合。
- **安全问题凸显：** 当大模型作为智能体控制权限时，可能引发恶意行为（如恶意发送辞职信、查询敏感信息、客服机器人滥用）。


2. 风险与挑战 07:52

1) 不可控风险 07:56




- **外部技术封控：** 2024年5月，美国众议院通过人工智能出口限制法案，限制源代码、论文、模型出口，存在“卡脖子”问题。
 - 美国大模型公司纷纷起诉中国公司“蒸馏”其数据。
- **破解之道：** 实现私域自主可控，即在自己的内部服务器上不受干扰地应用。

2) 不可信风险 08:41



- **无意识幻觉：** 模型编造虚假信息，且对提示文本中的信息把握存在偏移。
 - 案例：查询“北理工张华平博士”，模型编造出北方工业大学张华平博士的虚假简介。
 - 数据：休斯幻觉评估模型（HHEM）排行榜显示，最好的模型也存在约1%的幻觉。

- **真实案例:** 2023年纽约律师使用AI检索判例, AI编造了全部案例, 律师险些因此结束职业生涯。
 - **认知偏见:** 模型会放大训练数据中的偏见。
 - 案例: 在做饭场景图片识别中, 训练数据女性做饭者占66%, 但模型将84%的做饭者判断为女性, 显著高于真实比例。
- 3) 不可用风险 11:11




- **资源消耗战:** 截至2024年12月31日, 中国有302款生成式AI服务完成备案, 投入巨大。
 - 成本估算: 深度玩家需1万张N卡(每张约18万), 入门玩家需30张。
- **投入产出不对称:** 模型参数越来越大, 资源花销大, 训练周期长, 但性价比越来越差。
 - 黄氏定律: GPU将推动AI性能逐年翻倍, 但氧化比摩尔定律更大, 导致资源消耗持续膨胀。

3. 探索与应用 12:04


1) ChatBIT大模型 12:08

- ChatBIT大模型的基本情况 12:11



- **核心特点:** 领域优化、轻量可控。
 - 基于Transformer架构, 进行深度压缩和改造。
- **三大特性:**
 - **可信:** 全过程安全可信审查, 回答问题有依据, 客观问题基本解决幻觉问题。

- **敏捷：** 模型极度压缩，最小1.5B参数可装在普通笔记本电脑；最大320B参数可在两张卡的大模型一体机上运行。
 - **可控：** 数据、技术、平台全兼容国产自主可控平台。
- ChatBIT 1B与DeepSeek 7B的对比 13:36




	AIME24(sample)	AIME24(greedy)
Deepseek R1 7B	53.3	33.33
ChatBIT-DPO	56.67	-
ChatBIT-DPO变体 (ours)	58.89	46.67

张华平


-
- **数学竞赛成绩：** 在2024年AIME24数学竞赛中，ChatBIT-DPO变体多项指标超出DeepSeek R1 7B。
 - 例如：AIME24(greedy)中，ChatBIT-DPO变体得分46.67，DeepSeek R1 7B得分33.33。
- ChatBIT大模型角色扮演 13:49



-
- **实现流程：**
 - 收集角色相关材料（原稿、百科、背景、人物关系等）。
 - 提取角色档案、人物关系、思维方式，组织成角色数据集。
 - 用户提问时，将角色信息补充进提示词，让模型在特定身份、关系和世界观约束下进行角色扮演。
 - 案例：让模型扮演孙悟空，当用户问“取经路上有没有吃过汉堡和可乐”，模型回答“取经路上哪有什么汉堡可乐，少打岔，前面还有妖怪在等着呢”。
- 2) ChatBIT应用 14:35
- 数智赋能 14:38




-
- **LLM2BI系统: 基于人工智能的业务智能分析系统。**
 - **功能:** 将自然语言问题转化为数据库查询语言, 后台检索后生成答案, 并给出原文参考。
 - **案例:** 查询“习总书记关于国家总体安全观的具体论述”, 系统给出总结并附上习总书记原话参考。
 - **案例:** 查询“北理工、北航、哈工大三个学校A+和A学科数量”, 系统自动生成柱状图。
 - **案例:** 查询“张华平老师的信息”, 系统从数据库中调取个人数据。
- **核心价值:** 大模型成为人工智能底座, 自然语言对话成为主要接口, 改变了传统信息系统概念。
- **跨语言理解 15:56**




-
- **多语言支持:** 支持藏语、维吾尔语等数十种语言的交互。
 - **案例:** 输入英文专业文章, 可用中文与其进行交流。
- **多模态应用 16:13**



-
- 多模态校史讲述: 给一张照片, 模型能讲述背后的故事。
 - 案例: 钱学森大脑应用, 基于1821封书信、125篇文章等数据, 构建知识图谱, 模拟钱老思维。
- 长文档审阅 16:26



-
- 核心功能:
 - 参考文档查重: 自动检测参考文献是否重复。
 - 案例: 审阅张军院士《安全概论》一书, 发现第六章第2个和第16个参考文献重复。
 - 纠错: 检测书名、法规名称等错误。
 - 案例: 发现“中华人民共和国突发事件应对管理法”中多了“管理”二字。
 - 敏感检测: 检测全文敏感内容。
 - 整体建议: 对整本书给出修改建议, 如增加案例、增加国际视野等。
- 小狸个人助理 17:42




- - 数字员工应用: 全校第一位入职的数字员工，为教师提供教学服务。
 - 功能：课表推送、课堂直播申请、调停课指引、行程预定等。
- 3) ChatBIT大模型进入美国视野 17:52



-
- 国际关注: 2024年6月，北理工团队关于ChatBIT用于军事领域开源情报认知的论文，被美国路透社头版头条报道。
 - 报道称ChatBIT在军事对话和问答任务上优于其他模型。
 - 后续被美国媒体抹黑为“中国军方使用AI”，但实为乱港分子与中情局支持的智库的抹黑行动。

二、作业 18:12



-
- **创新实践题:** 如何利用开源大模型与OpenCloud打造一个具有创新特色的个人助理？
 - 要求：做出自己的特色，解决一个独具特色的个人助理问题。

三、知识小结

知识点	核心内容	考试重点/易混淆点	难度系数
语言模型定义	语言模型是计算一句话最大概率的生成组合方式	床前明月→光的案例说明概率分布；对象→男朋友 vs 对象→大象的语境差异	★★☆☆☆
N-gram语言模型	一元模型(只考虑自身)、二元模型(考虑前1个词)、三元模型(考虑前2个词)	不同n值对上下文依赖范围的差异	★★★☆☆
大语言模型“大”在何处	①上下文联想从3个词扩展到 3万个词 以上 ②训练数据从2亿字扩展到 TB级 全人类知识	上下文长度与训练样本规模的双重扩展	★★★★☆
大模型发展历程	1950-1980年N-gram → 深度语言模型 → 预训练语言模型 → 大型预训练模型(ChatGPT/DeepSeek)	各阶段技术演进的关键突破点	★★★★☆☆
大模型风险与挑战	①不可控风险(卡脖子问题) ②不可信风险(14.3%幻觉率 →最好模型仍有1%) ③认知偏见(做饭场景性别偏见) ④不可用风险(资源消耗战)	律师案例： AI编造判例导致职业危机； 性别偏见案例： 训练数据66%女性做饭→模型判断84%为女性	★★★★★
北理工ChatBIT大模型	特点：可信(数据安全审查)、敏捷(1.5B参数可装笔记本)、可控(国产自主可控)	2024年数学竞赛多项指标 超越DeepSeek	★★★★☆
大模型应用场景	角色扮演(孙悟空)、数字智能(思政问答)、数据查询(学科柱	文档审阅案例： 发现《安全概论》第	★★★★☆☆

	状图)、多语言交互(藏语/维吾尔语)、长文档审阅(参考文献查重)	六章第2和第16参考文献重复	
大模型发展趋势	能力接近饱和(比赛成绩98-99%); 主流形态从大模型转向 Agent ; 安全问题凸显(恶意发送辞职信/查询敏感信息)	虚线代表人类能力, 大模型能力逐渐接近饱和	★★★★☆

对比维度	传统语言模型(N-gram)	大语言模型(LLM)
上下文长度	3个词	3万个词以上
训练数据规模	2亿字(人民日报2年)	TB级 全人类知识
参数规模	百万级	十亿至千亿级
幻觉率	较低(规则驱动)	1-14.3% (需持续优化)
可控性	完全可控	存在 卡脖子风险
应用场景	简单文本生成	角色扮演/数字智能/多语言/文档审阅