

一、自然语言处理 00:21

1. 语言即世界 01:23

1) 自然语言处理缘起

● 自然语言处理缘起 01:28



-
- **核心哲学观点（维特根斯坦）：** 语言即世界，一个人的语言边界就是他世界的边界。

- **举例说明：**“负增长”本质是下降，“柔性就业”本质是失业。语言篡改并未改变客观现实，但重塑了人们对现实的反应（从负面情绪变为中性）。
- **学习外语的意义：** 不仅是掌握交流工具，更是为了扩大认知边界，学习语言背后的文化与思维方式。

● 自然语言处理缘起：巴别通天塔之惑 03:32



-
- **NLP的起源动机：** 解决人类因语言不同而产生的隔阂与冲突。
- **NLP的定义：** 用计算机处理人的自然语言（如中文、英文）。
 - **自然语言 vs 编程语言：** 自然语言（如中文）与人类打交道，充满歧义；编程语言（如C、Python）与计算机打交道，非常确定。
- **NLP的两大挑战：**
 - **歧义消解：** 同一句话可能有多种理解。
 - **人类知识：** 理解语言需要常识背景。

- **举例（常识背景）**：“中国乒乓球队谁也打不过”与“中国足球队谁也打不过”，用同样句式表达相反结果，依赖常识判断。
- **举例（歧义）**：“We do chicken right”字面翻译为“我们只做右撇子鸡”，实际含义是“我们是做鸡专家”。

2) 自然语言处理相关概念 05:42



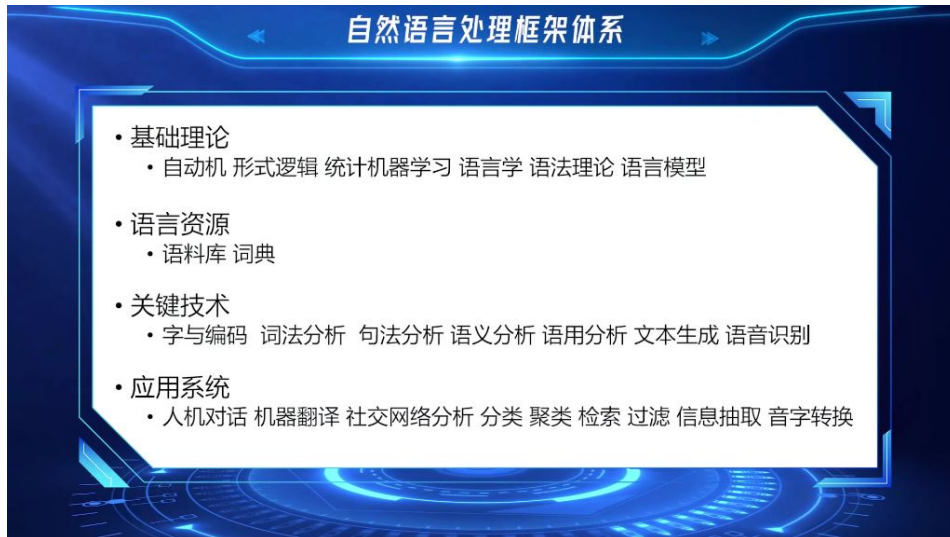
- **自然语言处理（技术概念）**：计算机科学、人工智能与计算语言学的交叉学科，用编程处理大规模自然语言语料库。
- **计算语言学（学科概念）**：从计算角度对自然语言进行统计或规则建模的交叉学科。
- **文本挖掘（应用概念）**：NLP技术的具体应用。

3) 自然语言处理过程 06:22




- **整体流程**：语音/图片 → 文本 → 结构化表示 → 数据挖掘 → 结果。
 - **语音输入**：通过语音识别转为文本。
 - **图片输入**：通过OCR转为文本。
 - **文本处理**：进行编码、词法、句法、语义、语用分析。
 - **结构化表示**：将文本转化为数字（如TF-IDF、词向量等）。
 - **数据挖掘**：应用统计学方法进行挖掘。
- **NLP过程三步走**：
 - **语言表示**：将语言结构化表示为数字。
 - **模型训练**：选择特征（字、词、短语）和模型，进行训练。
 - **处理优化**：部署模型，评测优化，迭代升级。

4) 自然语言处理框架体系 07:23



- 基础理论：自动机、形式逻辑、语言学语法理论、语言模型（如大语言模型）。
- 语言资源：语料库（生语料：未加工；熟语料：人工标注）、词典（单语、双语对照）。
- 关键技术：字与编码、词法分析、句法分析、语义分析、语用分析、文本生成、语音识别。
- 应用系统：人机对话、机器翻译、社交网络分析、分类聚类、检索过滤、信息抽取。


5) 自然语言处理技术演变 08:12



- 四大主义演变：
 - 理性主义（符号逻辑）：要求语言按规定的规则处理（如乔姆斯基句法结构）。
 - 经验主义（统计学习）：基于现有语言数据做统计（数据驱动方法）。
 - 连接主义（深度学习）：使用神经网络（如CNN、RNN、Transformer）。
 - 常识主义（预训练大模型）：基于大模型（如ChatGPT、DeepSeek）处理。
- 理性主义方法示例 09:24

理性主义方法示例：最短路径汉语分词


- 信息论原理：最小描述长度 (Minimum Description Length, MDL)
- 最短路径汉语分词：他/说/的/确实/在理



张华平,刘群.基于N-最短路径的中文词组粗分模型. 中文信息学报. 2002.9, Vol.16(5):pp.1-pp.7

- 原理：最小描述长度 (MDL)，用最短的文字长度表达信息。
- 应用：汉语分词。例如“他说的确实在理”，通过寻找最短路径进行分词（他/说/的/确实/在理）。
- 经验主义方法示例 10:05

- 原理：n-gram模型，计算概率，选择概率最大的分词结果。
- 应用：对“毛泽东诞生于1893年”进行分词，通过计算概率（如P(毛泽东|PER)）确定最佳切分。
- 技巧：取负log值，将乘法运算转为加法运算，便于计算。
- 连接主义方法示例 10:32



-
- **原理：**将字音嵌入和字形嵌入融合到深度学习网络中。
- **应用：**识别命名实体（人名、地名、机构名）。例如“爱国青年陈爱国”，模型需区分“爱国”（普通词）和“陈爱国”（人名）。
 - **核心观点：**中国人取名讲究好听（音）和好看（形），将音形特征加入神经网络自动学习。
- **常识主义方法示例 11:17**

常识主义方法示例：ChatBIT大模型抽取

• ChatBIT：北理工自主可控深度大模型

• 无需微调完成命名实体抽取任务

张华平

-
- **原理：**使用大模型（如北理工的ChatBIT），无需微调即可完成命名实体识别。
- **应用：**识别“留美归国的爱国青年陈爱国在爱国路聆听了费爱国院士讲爱国情怀”中的人名（陈爱国、费爱国）和地名（爱国路）。
 - **对比：**大模型方法更简单（无需训练），但效果通常比专用神经网络模型差。

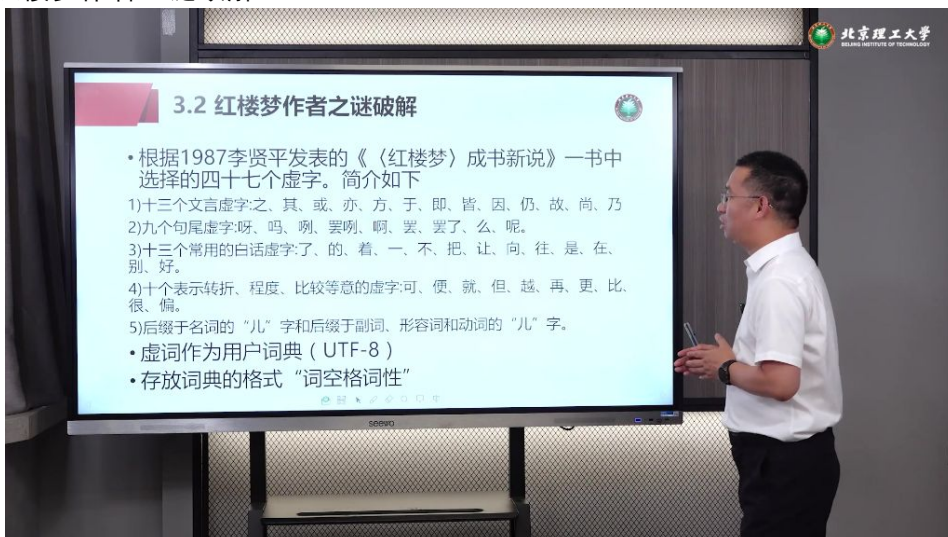
2. 应用与探索 12:13

1) 日本的实例 12:20



-
- **案件背景：**1999年，一名男子非正常死亡，现场有遗书，初步判定为自杀。其表弟领走巨额保险金，警方怀疑但无证据。
- **破案方法：**2003年，日本警方邀请同志社大学金明哲团队，通过文本挖掘技术分析相关文书。
 - **核心逻辑：**识别文章作者主要看**虚词**（如“的”、“了”、“过”等）。
 - **实验设计：**
 - M1：另一案件的文档（干扰项）。
 - M2：关于上保险的文档。
 - M3：目击者的检举信。
 - M4：遗书（分为奇数文和偶数文）。
 - **结果：**通过聚类分析，遗书（M4）与上保险文档（M2）的虚词使用模式高度一致，证明遗书是表弟伪造的。
 - **结论：**数学概率上推断遗书为表兄所写的概率接近100%（99.9%），与指纹识别原理类似。

2) 红楼梦作者之谜破解 15:31



-
- **研究基础：**基于1987年李贤平发表的《红楼梦成书新说》，选择47个虚字作为特征。
 - **虚字分类：**
 - 13个文言虚字：之、其、或、亦、方、于、即、皆、因、仍、故、尚、乃。
 - 9个句尾虚字：呀、吗、咧、罢咧、啊、罢、罢了、么、呢。
 - 13个白话虚字：了、的、着、一、不、把、让、向、往、是、在、别、好。

- 10个转折/程度/比较虚字：可、便、就、但、越、再、更、比、很、偏。
- 2个“儿”字：后缀于名词和副词/形容词/动词。
- 分析方法：
 - 特征表示：使用NLP工具自动计算前40回、中间40回、后40回中每个虚词的概率。
 - 模型选择：使用KL距离（相对熵）计算各组数据之间的差异。
 - 计算原理：概率相除取log再乘以概率，放大微小差异。
 - 结果：
 - 前40回与中间40回的KL距离为0.008（非常小）。
 - 前40回与后40回的KL距离为0.082（是前者的10倍）。
 - 结论：后40回的作者与前80回的作者不是同一人。

3) 某品牌幕后黑手破解 18:24



-
- 案例背景：大量用户在网上公开攻击某品牌。
- 分析方法：从8万条数据中抽取2万用户数据，发现200个异常账号。
- 结论：通过大数据结合NLP方法，识别出幕后操纵的黑手。

二、结束 19:26

- 本课作业（创新实践题）：利用社交媒体数据（如微博、朋友圈），通过NLP方法定量计算博主的性格特点（如MBTI、大五模型），并与心理学量表结果对比验证。

三、知识小结

知识点	核心内容	考试重点/易混淆点	难度系数
自然语言处理（NLP）定义	用计算机处理人类自然语言，与编程语言（C语言、Python）相对	自然语言 vs 形式化语言：自然语言有歧义，形式化语言确定无歧义	★★☆☆☆
语言即世界（维特根斯坦哲学）	语言的边界即世界的边界；语言改变可重塑认知，但不改变客观现实	“负增长”（下降）与“柔性就业”（失业）的认知差异	★★★☆☆
NLP两大挑战	①歧义消解 ②人类知识（常识背景）	示例：“谁也打不过”（中国乒乓球队 vs 中国足球队）含义相反	★★★★☆
NLP处理流程	语音/图片→文本→编码→词法/句法/语义/语用	三步：语言表示（数字结构化）→模型训练（特征	★★★★☆

	分析→结构化表示→模型训练→优化迭代	选择)→处理优化(迭代)	
NLP历史发展(四大主义)	①理性主义(乔姆斯基规则)②经验主义(统计概率)③链接主义(深度学习)④常识主义(大模型)	理性主义 vs 经验主义: 规则驱动 vs 数据驱动	★★★★★
汉语分词方法	最小描述长度(理性主义)、n-gram概率(经验主义)、神经网络(链接主义)、大模型(常识主义)	示例: “爱国青年陈爱国”中“爱国”是词, “陈爱国”是人名	★★★★☆
文本挖掘应用案例	①日本遗书伪造案(通过虚词分析识别作者)②红楼梦作者考证(47个虚字+KO距离)	虚词(之乎者也、了、过等)是作者识别关键特征	★★★★★
NLP实践题目	利用社交媒体数据(微博、微信)通过NLP计算性格(MBTI/大五模型)	需结合心理学量表验证结果一致性	★★★☆☆

对比维度	理性主义	经验主义	链接主义	常识主义
核心方法	规则驱动	统计概率	深度学习	大模型
代表技术	最小描述长度	n-gram	命名实体识别(CNN)	大语言模型(如北理工大模型)
优势	逻辑严谨	数据驱动	自动学习特征	无需训练, 调用简单
劣势	难以覆盖语言多样性	依赖数据质量	需大量标注数据	效果低于专用模型
应用示例	汉语分词规则	概率计算(毛泽东出生年)	人名识别(陈爱国)	多义消解(爱国路/费爱国)

案例	关键数据	结论
红楼梦作者考证	前40回与后40回距离: 0.082 (前40回与中间40回距离: 0.008)	后40回作者非曹雪芹, 概率 接近100%
日本遗书伪造案	遗书与表弟保险文档的虚词分布 高度重合	遗书伪造概率 99.9%
某品牌幕后黑手	8万数据中识别 200人 异常	发现幕后操纵者